

# Kopuły w analizie wielowymiarowych danych finansowych.

Piotr Mikler

# O czym dzisiaj?

- 1 Kopuły- po co?.
- 2 Kopuły - co to?.
- 3 Bivariate Copulas.
- 4 Struktury R-Vine.
- 5 Możliwe kierunki badań.
- 6 Q&A.

Historical Correlation<sup>1</sup>: January 2011–December 2020

	Positive	Negative	Investment Grade Bonds	Cash	Commodities	Currencies	Equity Market Neutral	Event Driven	Global	Hedge Funds	International Equity
High	0.7-1.0	(0.7)-(1.0)									
Moderate	0.4-0.7	(0.4)-(0.7)									
Low	0.0-0.4	(0.0)-(0.4)									
Investment Grade Bonds			1.00								
Cash			0.12	1.00							
Commodities			(0.17)	(0.12)	1.00						
Currencies			(0.04)	(0.03)	(0.47)	1.00					
Equity Market Neutral			0.05	(0.15)	0.35	(0.58)	1.00				
Event Driven			(0.05)	(0.25)	0.65	(0.33)	0.39	1.00			
Global			(0.03)	(0.16)	0.60	(0.49)	0.42	0.83	1.00		
Hedge Funds			0.10	(0.22)	0.60	(0.36)	0.50	0.91	0.84	1.00	
International Equity			(0.02)	(0.15)	0.60	(0.57)	0.45	0.80	0.96	0.81	1.00

Źródło: Guggenheim Investments.

FELIX SALMON

BUSINESS 02.23.2009 12:00 PM

## Recipe for Disaster: The Formula That Killed Wall Street

In the mid-'80s, Wall Street turned to the quants—brainy financial engineers—to invent new ways to boost profits. Their methods for minting money worked brilliantly... until one of them devastated the global economy.



## Definicja (Kopuła)

*d- wymiarowa kopuła  $C$  to dystrybuenta wielowymiarowego rozkładu o jednostajnych rozkładach brzegowych, określonego na  $d$ -wymiarowym hipersześcianie  $[0, 1]^d$ .*

## Twierdzenie (Gęstość kopuły)

*Gęstość kopuły  $c$  (dla kopuł absolutnie ciągłych) otrzymujemy poprzez pochodne cząstkowe, tzn.*

$$c(u_1, \dots, u_d) = \frac{\partial^d}{\partial u_1 \dots \partial u_d} C(u_1, \dots, u_d).$$

## Definicja (Kopuła Claytona)

*Kopułą Claytona o parametrze  $\theta \in [0; \infty)$  nazywamy:*

$$C(u_1, u_2; \theta) = (u_1^{-\theta} + u_2^{-\theta} - 1)^{-\frac{1}{\theta}}.$$

*Jej gęstość zadana jest więc przez:*

$$c(u_1, u_2; \theta) = (1 + \theta)(u_1^{-\theta} + u_2^{-\theta} - 1)^{-\frac{1+2\theta}{\theta}} (u_1 u_2)^{-(\theta+1)},$$

*gdzie w obu funkcjach  $(u_1, u_2) \in [0, 1]^2$ .*

# Przykład


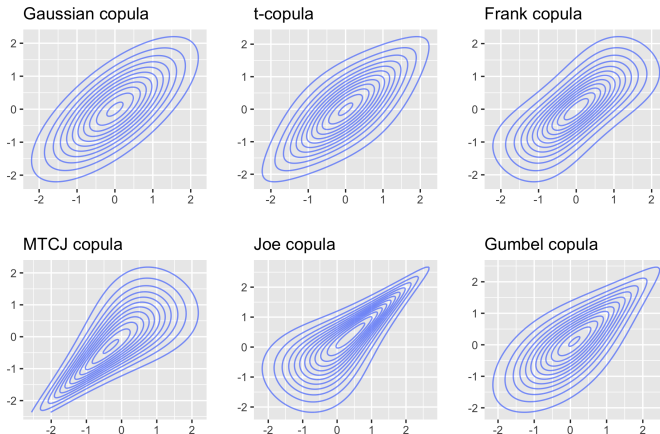


Figure: Kopała Claytona,  $\theta = 0.75$

# Gęstości kopuł



**Figure:** Gęstości wybranych kopuł.

Źródło: <https://bochang.me/blog/posts/copula/>



## Definicja (Kopuła)

*$d$ - wymiarowa kopuła  $C$  to dystrybuanta wielowymiarowego rozkładu o **jednostajnych rozkładach brzegowych**, określonego na  $d$ -wymiarowym hipersześcianie  $[0, 1]^d$ .*

## Twierdzenie (Probability integral transform)

*Jeśli  $X$  jest ciągłą zmienną losową o dystrybuancie  $F(x)$ , to  $U := F(X)$  ma rozkład jednostajny.*

# Probability integral transform






Figure: Transformacja zmiennej normalnej.

# Kopuły dwuwymiarowe



# Kopuły dwuwymiarowe



# Kopuły dwuwymiarowe




Figure: Kopuła Gumbela, Rotacja :  $180^\circ$ ,  $\theta = 1.61$

Co w przypadku rozkładów wielowymiarowych ( $d > 2$ ) ?

## Definicja (Pair-Copula Construction (PCC))

*Pair copula construction to dekompozycja wielowymiarowego rozkładu na komponenty jednowymiarowe, połączone już tylko dwuwymiarowymi kopułami.*

## Definicja (PCC typu D-vine)

*Każda gęstość łączna  $f_{1,...,d}$  może być zdekomponowana jako:*


$$f_{1,...,d}(x_1, \dots, x_d) = \left[ \prod_{j=1}^{d-1} \prod_{i=1}^{d-j} c_{i,(i+j);(i+1)\dots(i+j-1)} \right] \cdot \left[ \prod_{k=1}^d f_k(x_k) \right]$$

Rozważmy rozkład 6-wymiarowy  $[X_1, \dots, X_6]$  o gęstości  $f_{123456}(x_1, \dots, x_6)$ . Dekompozycji (jednej z ok. 23 tyś. możliwych!) można dokonać następująco:

$$\begin{aligned} f_{123456}(x_1, \dots, x_6) = & c_{26;1345} \cdot \\ & \cdot c_{25;134} \cdot c_{46;135} \cdot \\ & \cdot c_{45;13} \cdot c_{24;13} \cdot c_{36;15} \cdot \\ & \cdot c_{35;1} \cdot c_{14;3} \cdot c_{23;1} \cdot c_{16;5} \cdot \\ & \cdot c_{15} \cdot c_{34} \cdot c_{13} \cdot c_{12} \cdot c_{56} \cdot \\ & \cdot f_6 \cdot f_5 \cdot f_4 \cdot f_3 \cdot f_2 \cdot f_1. \end{aligned}$$

Przez  $c_{ij;klm}$  oznaczamy gęstość (dwuwymiarowej!) kopuły łączącej rozkłady warunkowe  $X_i|X_k, X_l, X_m$  oraz  $X_j|X_k, X_l, X_m$ .

# Struktury R-vine



Źródło: C.Czado, Analyzing Dependent Data with Vine Copulas



## Dalsze rozwinięcia konstrukcji kopułowych

- Rozkłady brzegowe zadane pewną strukturą (np. ARIMA, GARCH, itp.)
- Markov-switching copulas/ kopuła zmieniająca się w czasie
- Copula process

# Copula process - idea

Myśląc o procesie Wienera jako kolekcji zmiennych losowych o rozkładach normalnych, można próbować odzyskać strukturę zależności między nimi przy pomocy kopuły.

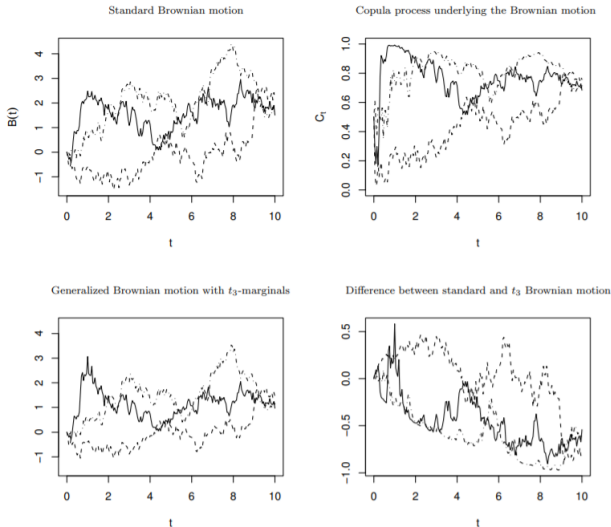
## Definicja (Kopuła Browna)

*Kopuła Browna to struktura zależności generowana przez proces Wienera. Możemy opisać ją za pomocą gęstości:*

$$c_{s,t}^B(u, v) = \sqrt{\frac{t}{t-s}} \frac{\varphi((\sqrt{t}\Phi^{-1}(v) - \sqrt{s}\Phi^{-1}(u))/\sqrt{t-s})}{\varphi(\Phi^{-1}(v))},$$

*gdzie  $s, t$  to indeksy czasowe, a  $\Phi, \varphi$  to dystrybuanta i gęstość standardowego rozkładu normalnego.*

# Kopuła Browna - idea



Źródło: V. Schmitz, Copulas and Stochastic Processes (2003).

*Dziękuję bardzo za uwagę!*